인코더-디코더 구조를 이용한 유도탄 데이터 점검 방법

A Guided Weapon Data Inspection Method Using an Encoder-Decoder Structure

저자명1) · 저자명*,2)
Author Name1) · Author Name*,2)
1) 소속기관명, 2) 소속기관명
1) Affiliation, 2) Affiliation, Korea

(Received 00 Month 2026 / Revised 00 Month 2026 / Accepted 00 Month 2026)

Abstract

Guided weapon development, test, and maintenance activities produce heterogeneous time-series records such as sensor measurements, status flags, and event logs. Before these data are used for engineering judgement, abnormal records caused by missing samples, frozen channels, timing mismatch, or inconsistent signal relationships should be detected in a repeatable way. This paper presents a simple encoder-decoder based inspection method for guided weapon data. The proposed method trains an encoder-decoder model only with normal or reviewed data windows, reconstructs each input window, and converts the reconstruction residual into an inspection score. The score is then combined with basic rule checks for missing values and range violations. The method is intentionally kept simple so that it can be introduced as a first screening layer before detailed domain review. A generic application procedure and review criteria are described without using classified specifications or operational parameters.

Key Words : Guided Weapon Data Inspection, Encoder-Decoder, Reconstruction Error, Telemetry, Data Quality

* Corresponding author, E-mail: author@example.com
Copyright (c) The Korea Institute of Military Science and Technology

1. 서 론

유도탄 체계의 개발, 시험, 저장, 정비 과정에서는 다수의 센서 계측값, 상태 플래그, 시험 이벤트, 점검 이력과 같은 시계열 데이터가 축적된다. 이러한 데이터는 체계 상태를 해석하고 후속 점검 여부를 판단하는 근거가 되므로, 분석에 앞서 결측, 비정상 범위, 고정값 지속, 시간 동기 불일치, 채널 간 관계 붕괴와 같은 데이터 품질 이상을 선별하는 절차가 필요하다. 기존 점검은 단일 채널 임계값이나 담당자 검토에 의존하는 경우가 많아 복합 패턴의 이상을 일관되게 걸러내기 어렵고, 데이터 규모가 커질수록 반복 검토 부담도 증가한다.

국내에서도 미사일 발사통제체계(FCS)의 DAS 주기 메시지를 대상으로 시계열 모델과 규칙 기반 임계값을 결합하여 시간 편차, 메시지 손실, 지터를 탐지하는 연구가 제안된 바 있다[10]. 또한 창정비 시험결과를 DB화하고 누적 Raw Data의 추이와 비교분석을 제공하는 연구는 시험 데이터 관리가 단순 합부 판정을 넘어 신뢰도 확인 절차로 확장될 필요가 있음을 보여준다[11].

본 논문은 유도탄 운용 세부나 성능 제원을 다루지 않고, 시험 및 정비 데이터의 사전 점검을 위한 단순한 인코더-디코더(Encoder-Decoder, Enc-Dec) 기반 방법을 제안한다. 인코더-디코더 구조는 입력 시퀀스를 잠재 표현으로 압축하고 이를 다시 복원하는 방식으로 시계열의 정상 패턴을 학습할 수 있으며[1,2], 정상 데이터만으로 학습한 뒤 복원 오차를 이상 점수로 사용하는 방식은 다중 센서 이상탐지 분야에서 널리 활용되어 왔다[3-5]. 본 연구의 목적은 복잡한 모델을 새로 설계하는 것이 아니라, 실무자가 이해하기 쉬운 데이터 점검 흐름을 제시하고 향후 체계별 규칙과 결합할 수 있는 기본 구조를 마련하는 데 있다.

제안 방법은 세 단계로 구성된다. 첫째, 채널별 단위와 시간 기준을 정렬하고 기본 품질 규칙을 적용한다. 둘째, 정상으로 확인된 구간을 일정 길이의 윈도우로 분할하여 Enc-Dec 모델을 학습한다. 셋째, 입력과 복원값의 차이를 채널별로 집계하여 이상 점수를 산출하고, 점검 담당자가 확인해야 할 우선순위를 제공한다. 이 절차는 지도 학습에 필요한 세부 고장 라벨이 충분하지 않은 초기 데이터 점검 환경에 적합하다.

2. 데이터 점검 대상과 문제 정의

2.1 점검 대상 데이터

본 논문에서의 유도탄 데이터는 특정 체계의 실제 제원이나 운용 절차가 아니라 일반화된 점검 데이터를 의미한다. 입력 데이터는 시간 순서가 있는 연속형 센서 값, 이산 상태 플래그, 시험 이벤트 로그, 정비 점검 결과로 구분할 수 있다. 예를 들어 관성 계측, 전원 상태, 온도 계열, 통신 상태, 안전 인터록과 같은 항목은 모두 서로 다른 단위와 샘플링 주기를 가질 수 있다. 따라서 본 연구에서는 데이터의 실제 의미를 자세히 해석하기보다, 분석 전 단계에서 발견되어야 하는 형식적·통계적 이상을 점검 대상으로 한정한다.

Table 1. Inspection targets and basic data-quality checks

Target	Typical record	Basic check
Sensor value	Continuous time-series channel	Missing sample, range violation, frozen value
Status flag	Discrete mode or health bit	Illegal transition, persistence,

		mismatch
Event log	Time-stamped test or maintenance event	Time order, duplicate record, missing event
Derived feature	Moving mean, difference, residual	Scale drift, correlation break, abrupt change

2.2 문제 정의

정상 데이터 집합을 X라고 할 때, 각 데이터 윈도우는 길이 T와 채널 수 C를 갖는 행렬로 표현된다. 점검 문제는 새로운 윈도우가 정상 운용 또는 정상 시험 절차에서 기대되는 패턴을 충분히 따르는지 판단하는 것이다. 이때 목표는 이상 원인을 단정하는 것이 아니라, 담당자가 우선 검토할 데이터 구간을 누락 없이 제시하는 것이다. 따라서 모델 출력은 합격 또는 불합격 판정만이 아니라, 채널별 복원 오차와 규칙 위반 내역을 함께 제공해야 한다.

본 논문은 다음과 같은 가정을 둔다. 정상 학습 데이터는 담당자 검토를 통해 명백한 오류가 제거된 구간으로 구성된다. 데이터는 체계별 보안 요구를 만족하는 내부 환경에서 처리된다. 모델은 무기 체계의 제어, 유도, 표적 식별 기능을 수행하지 않으며 데이터 품질 점검을 위한 보조 도구로만 사용된다. 이러한 가정은 제안 방법의 적용 범위를 데이터 검수 단계로 제한하고, 운용 판단은 기존 검토 절차와 도메인 전문가의 확인에 맡기기 위한 것이다.

무기체계 PHM 분야에서도 실제 고장 데이터 부족과 비정상 라벨 불균형이 주요 제약으로 지적되어 왔다[12]. 이러한 조건에서는 세부 고장 유형을 모두 분류하는 지도학습보다, 정상 기준선을 먼저 확보하고 데이터 사용 전 이상 가능 구간을 선별하는 점검 절차가 현실적인 출발점이 된다.

3. Enc-Dec 기반 점검 구조

Fig. 1은 제안하는 점검 흐름을 나타낸다. 입력 윈도우는 채널별 정규화와 결측 보간을 거친 뒤 인코더에 입력된다. 인코더는 시간적 변화를 낮은 차원의 잠재 벡터로 압축하고, 디코더는 해당 잠재 벡터로부터 원 입력 윈도우를 복원한다. 정상 패턴에서 자주 관측되는 변화는 작은 복원 오차를 보이지만, 학습 데이터에서 보기 어려운 신호 왜곡이나 채널 관계 변화는 상대적으로 큰 오차를 만든다.

[Input window] → [Encoder] → [Latent vector] → [Decoder] → [Residual and score]

Fig. 1. Simple encoder-decoder inspection flow

3.1 전처리와 윈도우 구성

전처리 단계에서는 채널별 시간 기준을 맞추고, 결측 구간을 표시한 뒤 필요한 경우 선형 보간 또는 직전값 유지 방식으로 모델 입력을 구성한다. 보간된 값은 원자료와 구분되어야 하며, 보간 비율이 일정 기준을 넘는 윈도우는 모델 점수와 별도로 규칙 위반으로 표시한다. 연속형 채널은 학습 데이터의 평균과 표준편차로 정규화하고, 이산 상태 플래그는 원-핫 또는 0/1 값으로 변환한다. 윈도우 길이는 점검 목적에 맞게 짧게 유지하여 한 구간의 점수가 과도하게 긴 시간 범위를 대표하지 않도록 한다.

유도탄 데이터는 시험 단계와 정비 단계에서 샘플링 주기와 기록 방식이 달라질 수 있다. 따라서 본 논문에서는 모든 채널을 하나의 복잡한 통합 모델에 넣기보다, 동일한 시간 기준으로 묶을 수 있는 채널군별 Enc-Dec 모델을 우선 적용하는 단순 구조를 권장한다. 예를 들어 전원·온도 계열, 자세·가속도 계열, 상태 플래그 계열을 분리하면 점검 결과의 설명성이 높아지고 모델 유지보수도 쉬워진다.

3.2 모델 구조

모델은 단순 LSTM 또는 1차원 합성곱 기반의 인코더와 대칭적인 디코더로 구성할 수 있다. 본 논문에서는 구현 복잡도를 낮추기 위해 두 개 이하의 은닉 계층과 작은 잠재 차원을 기본값으로 둔다. 복잡한 주의집중 구조나 그래프 모델은 채널 간 관계를 세밀하게 반영할 수 있지만[6,7], 초기 점검 체계에서는 모델 해석과 운영 안정성이 더 중요하다. 따라서 먼저 단순 모델로 기준 성능과 오탐 패턴을 파악한 뒤, 필요할 때만 구조를 확장하는 절차가 적절하다.

학습 목적함수는 입력 윈도우 x와 복원 윈도우 $xhat$의 평균제곱오차로 둔다. 채널 중요도가 다른 경우에는 채널 가중치 w를 적용할 수 있으나, 초기 적용에서는 동일 가중치를 사용하여 점수 해석을 단순화한다.

$$e_t = (1/C) \sum_c w_c (x_{t,c} - xhat_{t,c})^2$$

윈도우 점수는 시간별 오차의 평균 또는 상위 백분위값으로 계산한다. 평균은 전체적인 분포 변화를 잘 반영하고, 상위 백분위값은 짧은 급변 구간을 더 민감하게 포착한다. 실제 점검에서는 두 값을 함께 제시하고, 담당자가 확인한 결과를 바탕으로 임계값을 조정한다.

4. 점검 절차

4.1 정상 기준선 학습

정상 기준선 학습은 점검 체계의 신뢰도를 좌우하는 단계이다. 먼저 시험 또는 정비 담당자가 정상으로 확인한 구간만 학습 후보로 지정한다. 이후 기본 품질 규칙을 통해 결측률이 높거나 시간 순서가 깨진 구간을 제외한다. 남은 데이터는 훈련, 검증, 기준 산정 집합으로 나눈다. 훈련 집합은 모델 파라미터 학습에 사용하고, 검증 집합은 과적합 여부를 확인하며, 기준 산정 집합은 임계값을 계산하는 데 사용한다.

임계값은 기준 산정 집합의 복원 오차 분포에서 95 또

는 99 백분위값으로 시작할 수 있다. 다만 유도탄 데이터 점검에서는 놓침 비용과 오탐 비용이 모두 크므로, 단일 숫자만으로 운영 기준을 고정하지 않는 것이 바람직하다. 본 논문에서는 주의, 경고, 검토 필요의 세 단계 점수 구간을 두고, 각 구간에 대해 담당자 확인 절차를 연결하는 방법을 제안한다.

4.2 점검 실행과 결과 해석

새로운 데이터가 입력되면 동일한 전처리와 윈도우 분할을 적용하고, 각 윈도우의 복원 오차를 계산한다. 결과 화면에는 전체 점수만 표시하지 않고, 오차가 큰 채널, 규칙 위반 항목, 시간 구간, 원자료 링크를 함께 제공한다. 이는 모델이 이상 원인을 직접 설명하지 못하더라도 담당자가 빠르게 재검토할 수 있도록 하기 위한 최소 조건이다.

복원 오차가 높게 나타나는 경우는 세 가지로 나누어 해석한다. 첫째, 센서 또는 기록 장치의 실제 이상으로 인해 데이터 패턴이 정상 기준에서 벗어난 경우이다. 둘째, 시험 조건이 정상 학습 데이터와 달라 모델이 낯선 정상 패턴을 이상으로 표시한 경우이다. 셋째, 시간 정렬, 단위 변환, 결측 보간과 같은 전처리 문제로 모델 입력이 왜곡된 경우이다. 따라서 Enc-Dec 점수는 최종 판정이 아니라 재검토 우선순위로 사용되어야 한다.

Table 2. Review levels based on inspection score

Level	Condition	Recommended action
Notice	Score slightly exceeds normal band	Check preprocessing and recent test condition
Warning	Score exceeds threshold with channel concentration	Review raw channel and related event log
Review	Rule violation and high residual occur together	Escalate to domain reviewer before data use

5. 적용 예시와 기대 효과

본 절에서는 실제 유도탄 체계의 민감 정보를 사용하지 않고, 모의 점검 데이터를 가정하여 적용 절차를 설명한다. 모의 데이터는 연속형 채널군, 상태 플래그군, 이벤트 로그로 구성되며, 정상 구간에는 완만한 변화와 반복적인 시험 절차가 포함된다. 이상 구간에는 결측 샘플 증가, 특정 채널의 고정값 지속, 채널 간 시간 지연, 상태 플래그의 불가능한 전이, 이벤트 누락을 삽입한다. 이 예시는 방법의 사용 흐름을 설명하기 위한 것이며 실제 체계 성능이나 운용 조건을 나타내지 않는다.

Enc-Dec 모델은 정상 구간을 복원하도록 학습되므로, 고정값 지속이나 시간 지연과 같이 단일 임계값으로 발견하기 어려운 이상에서 상대적으로 큰 복원 오차를 만든다. 반면 단순 범위 초과나 결측은 규칙 기반 점검이 더 명확하게 탐지한다. 따라서 본 논문의 구조는 모델 점수와 규칙 위반을 병렬로 산출하여 상호 보완적으로 사용하는 데 초점을 둔다. 이러한 조합은 자동화된 점검 결과를 신뢰하기 전 담당자가 확인해야 할 근거를 남기는 장점이 있다.

Table 3. Example anomaly types and expected inspection cues

Type	Description	Main cue
Missing burst	Several consecutive samples are absent	Rule violation and interpolation ratio
Frozen channel	A channel keeps the same value abnormally	Low variance and high reconstruction error
Timing drift	One channel is delayed against related channels	Residual concentration in correlated channels
Flag mismatch	Status transition contradicts event order	State-rule violation

기대 효과는 세 가지로 정리된다. 첫째, 대량 데이터에서 우선 검토 구간을 줄여 담당자 검토 부담을 낮출 수 있다. 둘째, 정상 데이터만으로 학습할 수 있어 고장 라벨이 충분하지 않은 초기 단계에도 적용 가능하다. 셋째, 채널별 잔차와 규칙 위반을 함께 제공함으로써 점검 결과를 추적할 수 있다. 이러한 장점은 항공기 외관 결함 검출과 같이 군사 장비 점검에 딥러닝을 적용한 최근 연구 흐름과도 일치한다[8]. 다만 본 논문의 대상은 영상 기반 결함 검출이 아니라 시계열 데이터 사전 검수라는 점에서 적용 범위가 다르다.

6. 고 찰

제안 방법은 단순성과 적용 용이성을 우선한 구조이므로 몇 가지 한계가 있다. 첫째, 정상 학습 데이터의 범위가 좁으면 새로운 정상 시험 조건을 이상으로 판단할 수 있다. 둘째, 복원 오차는 이상 여부를 알려줄 수 있지만 물리적 원인을 직접 식별하지는 못한다. 셋째, 채널별 스케일과 보간 정책이 바뀌면 점수 분포도 달라지므로 데이터 처리 절차의 버전 관리가 필요하다. 넷째, 임계값은 체계, 시험 단계, 점검 목적에 따라 달라지므로 일회성 튜닝으로 고정해서는 안 된다.

운영 관점에서는 모델 관리 절차가 중요하다. 학습 데이터의 선정 기준, 제외된 데이터의 사유, 모델 버전, 임계값 산정 방식, 담당자 확인 결과를 함께 저장해야 한다. 또한 오탐이 반복되는 구간은 정상 범위 확장 여부를 검토하고, 미탐이 확인된 경우에는 규칙 기반 점검 항목을 보완해야 한다. 복잡한 모델로 바로 확장하기보다 단순 Enc-Dec 모델과 명시적 규칙의 조합을 유지하면, 점검 체계의 설명성과 재현성을 확보하기 쉽다.

FCS 환경에서도 제안 구조는 주기 메시지, 시간 간격, 메시지 손실 여부와 같은 입력을 사용하여 적용할 수 있다. 다만 기존 FCS 연구가 실시간 운용 메시지의 이상탐지에 초점을 둔다면[10], 본 논문은 특정 운용 기능의 자동 판정보다 시험·정비 데이터가 후속 분석에 사용될 수 있는지 확인하는 사전 점검 절차와 신뢰도 확보에 초점을 둔다. 따라서 산출물도 최종 고장 판정이 아니라 검토 우선순위, 규칙 위반 내역, 데이터 처리 이력으로 정의하는 것이 적절하다.

보안 측면에서도 입력 데이터와 산출 결과는 체계별 관리 기준에 따라 분리되어야 한다. 본 방법은 원자료의 민감한 수치나 운용 조건을 외부로 전송하지 않고 내부 점검 환경에서 실행하는 것을 전제로 한다. 논문에서 제시한 절차는 알고리즘 수준의 일반 구조이며, 실제 적용 시에는 보안 검토, 데이터 반출 통제, 접근 권한 관리가 선행되어야 한다.

7. 결 론

본 논문은 유도탄 데이터의 사전 점검을 위한 단순 Enc-Dec 기반 방법을 제안하였다. 제안 구조는 정상 데이터 윈도우를 학습한 뒤 복원 오차를 이상 점수로 산출하고, 결측·범위·상태 전이 규칙과 결합하여 담당자가 검토해야 할 구간을 제시한다. 복잡한 모델보다 단순한 구조를 우선 적용함으로써 초기 도입 시 해석성과 유지보수성을 확보할 수 있다. 향후 연구에서는 실제 비식별 시험 데이터에 대한 반복 검증, 채널군별 임계값 자동 보정, 담당자 피드백을 반영한 점검 기준 갱신 절차를 보완할 계획이다.

후 기

본 논문은 논문 형식 검토와 구조 초안 작성을 위한 예시이며, 실제 투고 전에는 저자 정보, 기관 승인, 데이터 보안성 검토, 실험 결과 및 수치 검증을 보완해야 한다.

Reference

[1] Cho, K., van Merrienboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. and Bengio, Y., “Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation,” Proceedings of EMNLP 2014, pp. 1724-1734, 2014.

[2] Sutskever, I., Vinyals, O. and Le, Q. V., “Sequence to Sequence Learning with Neural Networks,” Advances in Neural Information Processing Systems, Vol. 27, 2014.

[3] Malhotra, P., Ramakrishnan, A., Anand, G., Vig, L., Agarwal, P. and Shroff, G., “LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection,” arXiv:1607.00148, 2016.

[4] Kingma, D. P. and Welling, M., “Auto-Encoding Variational Bayes,” Proceedings of ICLR, 2014.

[5] Hundman, K., Constantinou, V., Laporte, C., Colwell, I. and Soderstrom, T., “Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding,” Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 387-395, 2018.

[6] Zhang, C., Song, D., Chen, Y., Feng, X., Lumezanu, C., Cheng, W., Ni, J., Zong, B., Chen, H. and Chawla, N. V., “A Deep Neural Network for Unsupervised Anomaly Detection and Diagnosis in Multivariate Time Series Data,” Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 33, No. 1, pp. 1409-1416, 2019.

[7] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. and Polosukhin, I., “Attention Is All You Need,” Advances in Neural Information Processing Systems, Vol. 30, 2017.

[8] Kim, J. and Choi, D., “Detection of Aircraft Defects in Walk Around Inspection(WAI) Using YOLO-based Deep Learning and Image Processing,” Journal of the Korea Institute of Military Science and Technology, Vol. 28, No. 6, pp. 564-574, 2025.

[9] Ester, M., Kriegel, H.-P., Sander, J. and Xu, X., “A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise,” Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining, pp. 226-231, 1996.

[10] Kim, H., Kwon, K., Choi, G., Moon, J. and Jung, H., "An AI-Based DAS Data Analysis for Real-Time Anomaly Detection in Missile Fire Control System," Proceedings of the KIMST Fall Conference, Guided Weapon System, pp. 599-600, 2025.

[11] Min, G. and Jin, J., "Development of DB Analysis SW for Depot Test-Equipment Based on Big Data," Proceedings of the KIMST Annual Conference, Structures and Machinery, pp. 73-74, 2025.

[12] Kim, G., Yoon, Y. A., Bak, B., Kim, M., Park, K., Jo, S. and Choi, H., "A Case Study on PHM Analysis Using Synthetic Data," Proceedings of the KIMST Annual Conference, Systems Engineering, pp. 1739-1740, 2022.